

Modelos de Aprendizado de Máquina

Aula 02: Tratamento de Dados Ausentes e Outliers

Agenda

Introdução a Imputação de Dados Ausentes e Outliers

Dados Ausentes (Missing Values): O que são dados ausentes num conjunto?


Técnicas de Imputação:
Quais as técnicas básicas de imputação?

Diferenciando Ruído de Outliers: O que é um ruído e o que é um outlier?

Tratamento Prático de Outliers: O tratamento

Séries temporais


- Uma série temporal é qualquer conjunto de observações **ordenadas no tempo**.
- As observações são dependentes do próprio tempo.
- Dados administrativos, econômicos, de engenharia ou de ciências naturais



Séries temporais

→ São compostas normalmente por quatro componentes:

- ◆ tendência (trend) - sentido de deslocamento
- ◆ sazonalidade - duração de curto prazo
- ◆ ruído - variabilidade intrínseca dos dados
- ◆ ciclo - movimento ao longo de vários anos



Média Móvel

- Uma técnica estatística que calcula a média de um subconjunto de dados (uma "janela" de tempo) que desliza ao longo de toda a série.
- $\hat{y}_t$ (ou MMS) é o valor estimado da tendência
- m é o tamanho da janela (pode ser dado em dias, meses, anos)
- y_t - são os valores da série


$$\hat{y}_t = \frac{1}{m} \sum_{i=-m+1}^0 y_{t+i}$$

ou


$$MMS = \frac{y_1 + y_2 + \dots + y_m}{m}$$

Analizando a tendência

SEG	TER	QUA	QUI	SEX	SAB	DOM
20	22	25	28	35	50	45
25	28	30	32	40	60	55





Analizando a tendência




JANELA	MÉDIA MÓVEL
SEG-DOM	32,14
TER-SEG	32,86
QUA-TER	33,71
QUI-QUA	34,43
SEX-QUI	35
SAB-SEX	35,71
DOM-SAB	37,14
SEG-DOM	38,57

Analizando a tendência



Analizando a tendência



Técnica de Decomposição

Modelo Aditivo: $Y_t = T_t + S_t + R_t$ (A série é a soma pura das partes).

Modelo Multiplicativo: $Y_t = T_t * S_t * R_t$ (A série é o produto das partes).

Encontrando um valor de sazonalidade

- A Série removida a tendência apresenta a fotografia de cada dia no tempo.
- Para encontrar a sazonalidade, nós temos que fazer a média do dia
- $(\text{Dom (Semana 1)} + \text{Dom (Semana 2)}) / 2$

14,65

Dia da Semana	Série Sem Tendência
Dom	+ 14,65
Seg	- 7,86
Ter	- 5,71
Qua	- 4,43
Qui	- 3,00
Sex	+ 4,29
Sáb	+ 22,86

Encontrando um valor de sazonalidade

- A Série removida a tendência apresenta a fotografia de cada dia no tempo.
- Para encontrar a sazonalidade, nós temos que fazer a média do dia
- $(\text{Dom (Semana 1)} + \text{Dom (Semana 2)}) / 2$

14,65

Dia da Semana	Série Sem Tendência
Dom	+ 14,65
Seg	- 7,86
Ter	- 5,71
Qua	- 4,43
Qui	- 3,00
Sex	+ 4,29
Sáb	+ 22,86

Dados Ausentes (Missing Values)

- Em séries temporais, a ordem das observações é fundamental
- Uma observação (registro) está intimamente relacionada às anteriores.
- Mas o que acontece quando um dado falta?

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Dados Ausentes (Missing Values)

→ Vamos supor que vamos calcular a média móvel da TER da SEM2 até SEG da SEM 3.

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Dados Ausentes (Missing Values)

→ Vamos supor que vamos calcular a média móvel da TER da SEM2 até SEG da SEM 3.

$$(28 + 30 + 32 + 40 + 60 + 55 + ??) / 7$$

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Dados Ausentes (Missing Values)

→ Vamos supor que vamos calcular a média móvel da TER da SEM2 até SEG da SEM 3.

$$(28 + 30 + 32 + 40 + 60 + 55) / 7$$

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Dados Ausentes (Missing Values)

- Vamos supor que vamos calcular a média móvel da TER da SEM2 até SEG da SEM 3.

245/ 7

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Dados Ausentes (Missing Values)

→ Vamos supor que vamos calcular a média móvel da TER da SEM2 até SEG da SEM 3.

35

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Impacto sobre a tendência

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

JANELA	MÉDIA MÓVEL
SEG-DOM	32,14
TER-SEG	32,86
QUA-TER	33,71
QUI-QUA	34,43
SEX-QUI	35
SAB-SEX	35,71
DOM-SAB	37,14
SEG-DOM	38,57
TER-SEG	35

Dados Ausentes (Missing Values)

- Vamos supor que vamos calcular a média móvel da TER da SEM2 até SEG da SEM 3.
- O valor ausente impacta no valor da tendência (média móvel)
- Precisamos resolver esse dado?
Como fazemos isso?

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Dados Ausentes (Missing Values)

- Vamos supor que vamos calcular a média móvel da TER da SEM2 até SEG da SEM 3.
- O valor ausente impacta no valor da tendência (média móvel)
- Precisamos resolver esse dado?
Como fazemos isso?

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Imputação de Dados

- Nos algoritmos tradicionais de imputação, nós usamos a média, mediana ou moda para preencher os dados.

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Imputação de Dados

- Nos algoritmos tradicionais de imputação, nós usamos a média, mediana ou moda para preencher os dados.
- Então vamos adicionar a média?

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Imputação de Dados

- Nos algoritmos tradicionais de imputação, nós usamos a média, mediana ou moda para preencher os dados.
- Então vamos adicionar a média?

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	35
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Imputação de Dados

- Nos algoritmos tradicionais de imputação, nós usamos a média, mediana ou moda para preencher os dados.
- Então vamos adicionar a média?

Não

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	35
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Imputação de Dados

- Nas séries temporais dois aspectos são fundamentais:
- ◆ a ordem das observações importa
 - ◆ os valores das observações possuem uma relação intrínseca com os dias.

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Técnicas de Imputação de Dados

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Técnicas de Imputação de Dados

→ **Forward fill (ffill / LOCF)**: Preenche o valor ausente com a última observação válida conhecida.

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Técnicas de Imputação de Dados

→ **Forward fill (ffill / LOCF)**: Preenche o valor ausente com a última observação válida conhecida.

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	55
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Técnicas de Imputação de Dados

- **Forward fill (ffill / LOCF):** Preenche o valor ausente com a última observação válida conhecida.
- **Backward Fill (bfill / NOCB):** Realiza o oposto do *ffill*, preenchendo a lacuna com a próxima observação válida registrada.

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Técnicas de Imputação de Dados

- **Forward fill (ffill / LOCF)**: Preenche o valor ausente com a última observação válida conhecida.
- **Backward Fill (bfill / NOCB)**: Realiza o oposto do *ffill*, preenchendo a lacuna com a próxima observação válida registrada.

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	25
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Técnicas de Imputação de Dados

- **Forward fill (ffill / LOCF):** Preenche o valor ausente com a última observação válida conhecida.
- **Backward Fill (bfill / NOCB):** Realiza o oposto do *ffill*, preenchendo a lacuna com a próxima observação válida registrada.
- **Interpolação Linear:** estima os valores ausentes ao assumir uma tendência linear constante entre os dois pontos conhecidos mais próximos.

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Técnicas de Imputação de Dados

→ **Interpolação Linear:** estima os valores ausentes ao assumir uma tendência linear constante entre os dois pontos conhecidos mais próximos.

◆ pontos mais próximos:

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Técnicas de Imputação de Dados

→ **Interpolação Linear:** estima os valores ausentes ao assumir uma tendência linear constante entre os dois pontos conhecidos mais próximos.

- ◆ pontos mais próximos: 25, 55
- ◆ Variação total:
 - valor = $25 - 55 = -30$
 - dias = $\text{TER} - \text{DOM} = 3 - 1 = 2$

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Técnicas de Imputação de Dados

→ **Interpolação Linear:** estima os valores ausentes ao assumir uma tendência linear constante entre os dois pontos conhecidos mais próximos.

- ◆ pontos mais próximos: 25, 55
- ◆ Variação total:
 - valor = $25 - 55 = -30$
 - dias = TER - DOM = $3 - 1 = 2$
- ◆ taxa constante: $-30 / 2 = -15$

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Técnicas de Imputação de Dados

- pontos mais próximos: 25, 55
- Variação total:
 - ◆ valor = $25 - 55 = -30$
 - ◆ dias = $\text{TER} - \text{DOM} = 3 - 1 = 2$
- taxa constante: $-30 / 2 = -15$
- valor projetado: $55 + (1 \times -15) = 55 - 15 = 40$

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Técnicas de Imputação de Dados

- pontos mais próximos: 25, 55
- Variação total:
 - ◆ valor = $25 - 55 = -30$
 - ◆ dias = $\text{TER} - \text{DOM} = 3 - 1 = 2$
- taxa constante: $-30 / 2 = -15$
- valor projetado: $55 + (1 \times -15) = 55 - 15 = 40$

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	40
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Técnicas de Imputação de Dados

- **Forward fill (ffill / LOCF):** Preenche o valor ausente com a última observação válida conhecida.
- **Backward Fill (bfill / NOCB):** Realiza o oposto do *ffill*, preenchendo a lacuna com a próxima observação válida registrada.
- **Interpolação Linear:** estima os valores ausentes ao assumir uma tendência linear constante entre os dois pontos conhecidos mais próximos.

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Diferenciando Ruídos e Outliers

- **Ruído:** São as variações aleatórias, imprevisíveis e irregulares que sobram na série após a remoção da tendência e da sazonalidade.
- **Outlier (Anomalia):** Um valor que desvia drasticamente do limite aceitável de variação, muitas vezes gerado por erros de sistema ou coleta.

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Tratamento prático de Outliers

→ **Detecção Contextual:** Em séries temporais, um ponto é considerado um outlier se ele foge drasticamente do padrão da média móvel local, não apenas da média global.

Dia da Semana	Semana 1	Semana 2	Semana 3
SEG	20	25	
TER	22	28	25
QUA	25	30	30
QUI	28	32	
SEX	35	40	40
SAB	50	60	50
DOM	45	55	52

Modelos de Aprendizado de Máquina

Aula 02: Tratamento de Dados Ausentes e Outliers