

Modelos de Aprendizado de Máquina

Aula 04: Métricas de Erro em Séries Temporais

Agenda

Introdução a Métricas de Erro e
Avaliação de Modelos de Series
Temporais

O que é o erro? Entendendo a
diferença entre real e predito

Métricas Básicas: Erro
Absoluto e Erro Relativo

Métricas Agregadas: MAE,
MSE, RMSE e MAPE

Validação: Considerações finais
sobre o desempenho

O Dataset Temporal Original

- Para entender como avaliamos um modelo, primeiro precisamos de uma série temporal real.
- Imagine que estamos acompanhando o **consumo diário de café** em uma cafeteria ao longo de uma semana.
- Este é o nosso dado observado, a verdade absoluta, que chamaremos de **Y_t** (Amostras Reais).

Dia (t)	Consumo Real (Y_t)
Segunda	20
Terça	25
Quarta	30
Quinta	40
Sexta	50

O Dataset Temporal Predito

- ➔ Agora, suponha que aplicamos um modelo preditivo (como uma média móvel) para tentar prever esse consumo.
- ➔ O modelo gerou estimativas matemáticas para cada dia.
- ➔ Chamaremos essa previsão de $\hat{Y}_t$ (Lê-se "Y chapéu").

Dia (t)	Consumo Real (Y_t)	Previsão ($\hat{Y}_t$)
Segunda	20	22
Terça	25	23
Quarta	30	30
Quinta	40	35
Sexta	50	55

Avaliando a Qualidade

- Nós temos os dados reais (o que aconteceu) e os dados preditos (o que o modelo achou que ia acontecer).
- A pergunta central da Ciência de Dados é:
Quão boa foi a nossa previsão?
- Nesta etapa de avaliação, o nosso objetivo matemático e de negócios é único e claro:
reduzir ao máximo o erro.
- Para reduzir o erro, precisamos primeiro aprender a medi-lo corretamente.

Dia (t)	Consumo Real (Y_t)	Previsão ($\hat{Y}_t$)
Segunda	20	22
Terça	25	23
Quarta	30	30
Quinta	40	35
Sexta	50	55

O que é o erro?

- O erro de previsão é a distância matemática entre a realidade e a nossa estimativa.
- Se o erro for zero, significa que o nosso modelo fez uma previsão perfeita para aquele momento.
- **Erros Positivos:** Ocorrem quando o valor real foi maior que a previsão (o modelo subestimou a realidade).
- **Erros Negativos:** Ocorrem quando o valor real foi menor que a previsão (o modelo superestimou a realidade).

$$e_t = Y_t - \hat{Y}_t$$

O componente de Erro

- A fórmula mais elementar para descobrir o erro simples em um ponto específico do tempo (t) é a subtração:

$$e_t = Y_t - \hat{Y}_t$$

- No entanto, apenas somar esses erros simples de todos os dias gera um problema: **os erros positivos e negativos vão se cancelar**, dando a falsa impressão de que o modelo é excelente.

Erro Absoluto

- Para evitar que erros positivos e negativos se anulem, utilizamos o conceito de módulo da matemática.
- O **Erro Absoluto** foca exclusivamente na **magnitude** do erro, ignorando totalmente a direção (se foi um erro para mais ou para menos).
- Geometricamente, é a distância absoluta, em linha reta, entre a curva do dado real e a curva da previsão no gráfico.

$$| e_t | = | Y_t - \hat{Y}_t |$$

Erro Absoluto: Fórmula

→ A representação matemática utiliza as barras de módulo:

$$| e_t | = | Y_t - \hat{Y}_t |$$

→ Se o valor real for 20 e a previsão 22, a diferença é -2. O Erro Absoluto será **2**.

→ Se o valor real for 40 e a previsão 35, a diferença é 5. O Erro Absoluto continua sendo **5**.

Erro Absoluto: Passo a Passo

Dia	Real (Y)	Predito ($\hat{Y}$)	Cálculo Simples ($Y - \hat{Y}$)	Erro Absoluto $ e $
Seg	20	22	$20 - 22 = -2$	2
Ter	25	23	$25 - 23 = 2$	2
Qua	30	30	$30 - 30 = 0$	0
Qui	40	35	$40 - 35 = 5$	5
Sex	50	55	$50 - 55 = -5$	5

Erro Absoluto

- Olhar para os erros absolutos isoladamente nos diz pouco sobre a qualidade geral do modelo na semana inteira.
- Além disso, surge uma dúvida de escala: errar "5 cafés" é muito ou pouco?
- Se a loja vende 10 cafés no total, errar 5 é um desastre. Se ela vende 5.000 cafés, errar 5 é uma precisão espetacular.
- Para resolver essa limitação da escala, precisamos introduzir o conceito de **Erro Relativo**.

$$| e_t | = | Y_t - \hat{Y}_t |$$

Erro Relativo

- O Erro Relativo compara o tamanho do erro cometido com o tamanho do valor real que estávamos tentando prever.
- Ele expressa o desvio em forma de **proporção**.
- Isso normaliza a nossa métrica, permitindo que a gente saiba o peso real daquele erro independente do volume de vendas daquele dia.
- Basta dividir o Erro Absoluto encontrado pelo valor Real daquele ponto no tempo.

$$\text{Erro Relativo} = \frac{|Y_t - \hat{Y}_t|}{|Y_t|}$$

Erro Relativo

➔ Basta dividir o Erro Absoluto encontrado pelo valor Real daquele ponto no tempo.

$$\text{Erro Relativo} = \frac{|Y_t - \hat{Y}_t|}{|Y_t|}$$

➔ O resultado será um número decimal que pode ser facilmente convertido para porcentagem multiplicando por 100.

Erro Relativo

Dia	Real (Y)	Erro Abs.	Cálculo (Abs / Real)	Erro Relativo (%)
Seg	20	2	$2 / 20 = 0.10$	10.0%
Ter	25	2	$2 / 25 = 0.08$	8.0%
Qua	30	0	$0 / 30 = 0.00$	0.0%
Qui	40	5	$5 / 40 = 0.125$	12.5%
Sex	50	5	$5 / 50 = 0.10$	10.0%

Erro Relativo

- Apresentar o desvio em porcentagem é extremamente poderoso e fácil de ser interpretado por equipes de negócios.
- No entanto, ainda estamos olhando para um dia de cada vez.
- Na Ciência de Dados, precisamos de métricas que avaliem a série temporal como um todo (o modelo global, não apenas um dia isolado).
- Para isso, vamos usar as métricas agregadas:
MAE, MSE, RMSE e MAPE.

$$\text{Erro Relativo} = \frac{|Y_t - \hat{Y}_t|}{|Y_t|}$$

MAE (Mean Absolute Error)

- O **Erro Absoluto Médio** (MAE) é, como o nome diz, a média aritmética de todos os erros absolutos da nossa série temporal.
- Ele consolida todo o desempenho do modelo em um único número.
- Ele responde à pergunta: **"Em média, por quantas unidades as minhas previsões estão errando?"**

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t|$$

MAE (Mean Absolute Error)

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n | Y_t - \hat{Y}_t |$$

- **n**: É o número total de amostras (dias analisados).
- **Σ (Sigma)**: Indica o somatório matemático de todos os períodos.
- Basicamente, somamos todos os Erros Absolutos e dividimos pela quantidade de dias.

MAE (Mean Absolute Error)

Dia	Erro Absoluto
Segunda	2
Terça	2
Quarta	0
Quinta	5
Sexta	5

Soma dos Erros Absolutos = $2 + 2 + 0 + 5 + 5 = 14$

$$\text{MAE} = 14 / 5 = 2.8$$

MAE (Mean Absolute Error)

- O valor do MAE calculado foi de **2.8**.
- **O que isso significa?** Significa que, na semana analisada, nosso modelo errou a previsão em média por 2.8 cafés por dia.
- **Vantagem:** É altamente interpretável, pois continua na mesma unidade de medida dos dados originais. Trata todos os erros com o mesmo peso.

Dia	Erro Absoluto
Segunda	2
Terça	2
Quarta	0
Quinta	5
Sexta	5

Soma dos Erros Absolutos = $2 + 2 + 0 + 5 + 5 = 14$

$$\text{MAE} = 14 / 5 = 2.8$$

MSE (Mean Squared Error)

- O **Erro Quadrático Médio** (MSE) é uma métrica fundamental em Machine Learning, especialmente para treinamento de modelos.
- Em vez de tirar o módulo, ele eleva a diferença entre o real e o predito ao quadrado.
- O objetivo de elevar ao quadrado não é apenas remover o sinal negativo, mas principalmente **penalizar de forma agressiva os grandes erros.**

$$\text{MSE} = \frac{1}{n} \sum_{t=1}^n Y_t - \hat{Y}_t^2$$

MSE: Fórmula

$$\text{MSE} = \frac{1}{n} \sum_{t=1}^n Y_t - \hat{Y}_t^2$$

- ➔ Repare que substituímos o módulo absoluto $||$ pelos parênteses elevados ao quadrado $()^2$.
- ➔ Um erro simples de 2, ao quadrado, vira 4. Um erro de 5, ao quadrado, explode para 25. O modelo "sofre" mais com desvios maiores.

MSE: Passo a Passo

Dia	Erro Simples ($Y - \hat{Y}$)	Erro ao Quadrado ($Y - \hat{Y}$) ²
Seg	-2	$(-2)^2 = 4$
Ter	2	$(2)^2 = 4$
Qua	0	$(0)^2 = 0$
Qui	5	$(5)^2 = 25$
Sex	-5	$(-5)^2 = 25$

Soma dos Quadrados = $4 + 4 + 0 + 25 + 25 = 58$

$$\text{MSE} = 58 / 5 = 11.6$$

MSE (Mean Squared Error)

- O valor do MSE calculado foi de **11.6**.
- Mas qual a unidade disso? São "cafés ao quadrado". Isso torna a interpretação direta impossível para um ser humano.
- **Desvantagem:** Difícil explicação para áreas de negócio.
- **Vantagem:** Excelente para otimização matemática (matematicamente suave e derivável), por isso é a função de perda favorita de algoritmos baseados em gradiente (como redes neurais).

Dia	Erro Simples ($Y - \hat{Y}$)	Erro ao Quadrado ($Y - \hat{Y}$) ²
Seg	-2	$(-2)^2 = 4$
Ter	2	$(2)^2 = 4$
Qua	0	$(0)^2 = 0$
Qui	5	$(5)^2 = 25$
Sex	-5	$(-5)^2 = 25$

Soma dos Quadrados = $4 + 4 + 0 + 25 + 25 = 58$

$$\text{MSE} = 58 / 5 = 11.6$$

RMSE (Root Mean Squared Error)

- A **Raiz do Erro Quadrático Médio** (RMSE) foi criada justamente para resolver o problema de interpretação do MSE.
- Ao aplicarmos a raiz quadrada no resultado do MSE, nós forçamos a métrica a retornar para a mesma escala e unidade dos dados originais.
- É, sem dúvidas, uma das métricas mais utilizadas na indústria para avaliar modelos preditivos de regressão e séries temporais.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n Y_t - \hat{Y}_t^2}$$

RMSE (Root Mean Squared Error)

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n Y_t - \hat{Y}_t^2}$$

➔ A fórmula é exatamente a mesma do MSE, mas envolta por uma enorme raiz quadrada (Root).

RMSE (Root Mean Squared Error)

- Como já realizamos todo o cálculo pesado no passo anterior, encontrar o RMSE é muito simples.
- O nosso MSE resultou em **11.6**.
- Basta aplicar a raiz
- O valor do RMSE calculado foi de **3.4** cafés.
- Repare: O RMSE (3.4) é **maior** que o MAE (2.8). Isso sempre acontece quando há variabilidade nos erros (outliers puxam a métrica quadrada para cima).

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n Y_t - \hat{Y}_t^2}$$

$$\text{RMSE} = \sqrt{11.6}$$

$$\text{RMSE} \approx 3.4$$

RMSE (Root Mean Squared Error)

- O valor do RMSE calculado foi de **3.4** cafés.
- Repare: O RMSE (3.4) é **maior** que o MAE (2.8). Isso sempre acontece quando há variabilidade nos erros (outliers puxam a métrica quadrada para cima).
- **Quando usar?** Se o seu negócio não tolera grandes erros (ex: prever um pico de demanda absurdo pode quebrar seu estoque), você deve focar em minimizar o RMSE do seu modelo, pois ele pune severamente as grandes distorções.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n Y_t - \hat{Y}_t^2}$$

$$\text{RMSE} = \sqrt{11.6}$$

$$\text{RMSE} \approx 3.4$$

MAPE (Mean Absolute Percentage Error)

- O **Erro Percentual Absoluto Médio** (MAPE) é a agregação de todos os erros relativos ao longo do tempo.
- É a métrica queridinha de gestores e diretores, pois traduz a performance complexa do modelo em uma simples e compreensível taxa percentual.
- Permite comparar a eficiência do modelo entre diferentes produtos de escalas muito variadas.

$$MAPE = \frac{100\%}{n} \sum_{t=1}^n \frac{Y_t - \hat{Y}_t}{Y_t}$$

MAPE (Mean Absolute Percentage Error)

$$\text{MAPE} = \frac{100\%}{n} \sum_{t=1}^n \frac{Y_t - \hat{Y}_t}{Y_t}$$

- Calculamos o erro relativo absoluto de cada ponto.
- Somamos todos eles.
- Dividimos pelo número de dias (tirando a média) e multiplicamos por 100 para transformar o decimal em porcentagem.

MAPE: Passo a Passo

Dia	Erro Relativo (%)
Segunda	10.0%
Terça	8.0%
Quarta	0.0%
Quinta	12.5%
Sexta	10.0%

Soma das Porcentagens = $10 + 8 + 0 + 12.5 + 10 = \mathbf{40.5\%}$

$$\mathbf{MAPE = 40.5\% / 5 = 8.1\%}$$

MAPE (Mean Absolute Percentage Error)

- O valor do MAPE foi de **8.1%**. Nosso modelo erra suas previsões em 8.1%, em média. Uma precisão de quase 92%!
- **Atenção ao Risco Matemático:** Se em algum dia a cafeteria não vender nenhum café (Venda Real $Y_t = 0$), a fórmula exigirá uma **divisão por zero**.
- O MAPE não pode (e não deve) ser calculado para séries temporais que possuem valores zerados. Nesses casos, o cálculo quebra.

Dia	Erro Relativo (%)
Segunda	10.0%
Terça	8.0%
Quarta	0.0%
Quinta	12.5%
Sexta	10.0%

Soma das Porcentagens = $10 + 8 + 0 + 12.5 + 10 = \mathbf{40.5\%}$

$$\mathbf{MAPE = 40.5\% / 5 = 8.1\%}$$

Considerações Finais

- **A Importância do Teste:** Nunca confie cegamente no erro dos dados de treino. A qualidade do seu modelo deve ser validada nos dados que o modelo *ainda não viu* (separação em amostras de Treino e Teste).
- **Não existe uma única métrica perfeita:**
 - ♦ Use **MAE** para uma média honesta e pouco influenciada por anomalias.
 - ♦ Use **RMSE** quando erros grandes custam caro e precisam ser evitados.
 - ♦ Use **MAPE** para apresentar resultados comerciais limpos e comparáveis (desde que a série não tenha zeros).
- Um modelo não é bom por si só. Ele é considerado bom quando seu erro (**seja MAE, RMSE ou MAPE**) é consistentemente menor que o erro de outros modelos concorrentes.

Modelos de Aprendizado de Máquina

Aula 04: Métricas de Erro em Séries Temporais